

BÀI TẬP TÌNH HUỐNG

PHÂN TÍCH BÁN HÀNG VỚI PYSPARK

Sales Analytics with PySpark – Online Retail II

1. Mục tiêu học tập

- Đọc và xử lý tập dữ liệu giao dịch bán hàng quy mô lớn bằng PySpark DataFrame.
- Làm sạch dữ liệu giao dịch: missing values, đơn hủy, số lượng/đơn giá bất hợp lệ.
- Xây dựng các KPI bán hàng: Revenue, Orders, Customers, AOV, Units Sold.
- Phân tích doanh thu theo thời gian, sản phẩm, quốc gia và khách hàng bằng DataFrame API và Spark SQL.
- Ứng dụng Window Function và RFM để phân tích hành vi khách hàng.
- Chuyển kết quả phân tích kỹ thuật thành nhận định và đề xuất kinh doanh.

2. Bối cảnh bài toán

Bạn đang làm Data Analyst cho một doanh nghiệp bán lẻ trực tuyến. Ban quản lý muốn hiểu hiệu quả bán hàng, xu hướng doanh thu, sản phẩm chủ lực, thị trường quan trọng và nhóm khách hàng có giá trị cao. Dữ liệu giao dịch khá lớn nên nhóm phân tích sử dụng Apache Spark/PySpark để xử lý và tổng hợp dữ liệu.

3. Dataset: UCI Online Retail II

Nguồn đề xuất: UCI Machine Learning Repository - Online Retail II (Daqing Chen).

Dataset chứa 1.067.371 dòng giao dịch của một nhà bán lẻ trực tuyến tại Anh trong giai đoạn 01/12/2009 - 09/12/2011. Dữ liệu có missing values và giao dịch hủy, rất phù hợp để thực hành data cleaning và sales analytics.

Nguồn: <https://archive.ics.uci.edu/dataset/502/online+retail+ii>

DOI: 10.24432/C5CG6D | License: CC BY 4.0

Từ điển dữ liệu:

Biến	Ý nghĩa
InvoiceNo	Mã hóa đơn; mã bắt đầu bằng C biểu thị giao dịch hủy
StockCode	Mã sản phẩm
Description	Tên/mô tả sản phẩm
Quantity	Số lượng sản phẩm trong dòng giao dịch
InvoiceDate	Ngày và thời gian phát sinh hóa đơn
UnitPrice	Đơn giá sản phẩm, GBP
CustomerID	Mã khách hàng
Country	Quốc gia của khách hàng

4. Chuẩn bị môi trường

- Khuyến nghị: Google Colab hoặc Jupyter Notebook có Java + PySpark.

- Notebook đi kèm có đoạn mã tải file ZIP từ UCI, giải nén file Excel và chuyển sang CSV để Spark đọc thuận tiện.

```
pip install pyspark pandas openpyxl
from pyspark.sql import SparkSession
spark = SparkSession.builder.appName('SalesAnalytics').getOrCreate()
```

5. NỘI DUNG BÀI LÀM

Phần A: Data Understanding & Data Cleaning

Bài 1. Khám phá dữ liệu

1. Đọc dữ liệu bằng `spark.read.csv(...)`.
2. Hiển thị 20 dòng đầu, schema, số dòng và số cột.
3. Đếm số giá trị thiếu của từng cột.
4. Đếm số hóa đơn, khách hàng, sản phẩm và quốc gia phân biệt.
5. Xác định khoảng thời gian dữ liệu.

Câu hỏi: Vì sao số dòng giao dịch khác số hóa đơn? Một hóa đơn có thể chứa nhiều dòng sản phẩm như thế nào?

Bài 2. Làm sạch dữ liệu

6. Chuyển `InvoiceDate` sang `timestamp`.
7. Tạo cờ `IsCancelled` nếu `InvoiceNo` bắt đầu bằng C.
8. Thống kê số dòng giao dịch hủy và tỷ lệ hủy.
9. Kiểm tra `Quantity <= 0` và `UnitPrice <= 0`.
10. Tạo `DataFrame sales_clean` chỉ giữ giao dịch bán hợp lệ: không hủy, `Quantity > 0`, `UnitPrice > 0`.
11. Giữ các dòng thiếu `CustomerID` cho phân tích tổng doanh thu, nhưng tạo thêm `sales_customer` cho các bài toán khách hàng.

```
sales_clean = df.filter((~F.col('InvoiceNo').startswith('C')) & (F.col('Quantity') > 0) & (F.col('UnitPrice') > 0))
```

Phần B: Xây dựng KPI bán hàng

Bài 3. Feature Engineering

12. Tạo `Revenue = Quantity × UnitPrice`.
13. Tạo `Year`, `Month`, `YearMonth`, `DayOfWeek`, `Hour` từ `InvoiceDate`.
14. Tạo trường `Date` để phân tích doanh thu theo ngày.

```
df = sales_clean.withColumn('Revenue', F.col('Quantity') * F.col('UnitPrice'))
```

Bài 4. KPI tổng quan

Tính các KPI sau và trình bày thành bảng tóm tắt:

KPI	Công thức / cách tính
Revenue	SUM(Revenue)

Orders	COUNT DISTINCT InvoiceNo
Units Sold	SUM(Quantity)
Customers	COUNT DISTINCT CustomerID
AOV	Revenue / Orders
Revenue per Customer	Revenue / Customers
Avg. Items per Order	Units Sold / Orders

Yêu cầu phân tích: Viết 3–5 câu nhận xét về quy mô hoạt động của doanh nghiệp, không chỉ in con số.

Phần C: Sales Performance Analysis

Bài 5. Phân tích theo thời gian

15. Tính doanh thu theo tháng và sắp xếp theo thời gian.
16. Tính số đơn hàng theo tháng.
17. Tính AOV theo tháng.
18. Tìm 10 ngày có doanh thu cao nhất.
19. Phân tích doanh thu theo thứ trong tuần và theo giờ trong ngày.
20. Nhận xét về mùa vụ và thời điểm bán hàng cao điểm.

Bài 6. Phân tích sản phẩm

21. Top 20 sản phẩm theo doanh thu.
22. Top 20 sản phẩm theo số lượng bán.
23. Top 20 sản phẩm theo số đơn hàng chứa sản phẩm.
24. Tìm các sản phẩm có doanh thu cao nhưng số lượng bán không cao và giải thích.
25. Tính tỷ trọng doanh thu của Top 10, Top 20 và Top 100 sản phẩm.

Câu hỏi kinh doanh: Doanh nghiệp có phụ thuộc quá nhiều vào một nhóm nhỏ sản phẩm hay không?

Bài 7. Phân tích theo quốc gia

26. Doanh thu và số đơn hàng theo Country.
27. Top 10 quốc gia ngoài United Kingdom theo Revenue.
28. AOV theo Country với điều kiện quốc gia có ít nhất 50 đơn hàng.
29. So sánh UK và thị trường quốc tế.

Phần D: Customer Analytics & RFM

Bài 8. Phân tích khách hàng

30. Top 20 khách hàng theo doanh thu.
31. Số đơn hàng và doanh thu trung bình trên khách hàng.
32. Tính tỷ trọng doanh thu của Top 1%, 5% và 10% khách hàng.
33. Phân tích mức độ tập trung doanh thu theo khách hàng.

Bài 9. RFM Analysis

Với từng CustomerID, tính:

Chỉ số	Định nghĩa
Recency	Số ngày từ lần mua gần nhất tới ngày tham chiếu = $\max(\text{InvoiceDate}) + 1$ ngày
Frequency	Số hóa đơn khác nhau của khách hàng
Monetary	Tổng Revenue của khách hàng

Chấm điểm R, F, M theo 5 nhóm (1-5) bằng ntile hoặc percentile. Tạo RFMScore và phân nhóm khách hàng theo quy tắc đơn giản: Champions, Loyal, Potential Loyalist, At Risk, Lost/Other.

```
w_r = Window.orderBy(F.col('Recency').desc())
w_f = Window.orderBy(F.col('Frequency'))
w_m = Window.orderBy(F.col('Monetary'))
```

Yêu cầu: Với mỗi segment, tính số khách hàng, Revenue, Revenue trung bình, Frequency trung bình và đề xuất một hành động marketing phù hợp.

Phần E: Spark SQL

Bài 10. Truy vấn SQL

Tạo temporary view sales và viết ít nhất 6 truy vấn Spark SQL:

34. Doanh thu theo tháng.
35. Top 10 sản phẩm theo Revenue.
36. Top 10 khách hàng theo Revenue.
37. Top 10 quốc gia ngoài UK.
38. Các tháng có AOV cao nhất.
39. Sản phẩm xuất hiện trong nhiều hóa đơn nhất.

```
sales.createOrReplaceTempView('sales')
spark.sql('SELECT ... FROM sales GROUP BY ...')
```

Phần F: Câu hỏi phân tích kinh doanh

Không chỉ chạy code. Anh/chị phải trả lời tối thiểu 6 câu hỏi sau bằng số liệu/biểu đồ:

- Xu hướng doanh thu theo thời gian như thế nào? Có dấu hiệu mùa vụ hay không?
- Sản phẩm nào thực sự quan trọng nếu xét đồng thời Revenue, Quantity và số hóa đơn?
- Thị trường ngoài UK nào có tiềm năng nhất?
- Doanh thu có tập trung vào một số ít khách hàng hay không?
- Nhóm RFM nào tạo ra phần lớn doanh thu?
- Nhóm khách hàng nào nên được ưu tiên giữ chân?
- Tỷ lệ hủy giao dịch có đáng kể hay không và có tập trung theo sản phẩm/thị trường?

- Từ dữ liệu hiện tại, đề xuất 3 hành động kinh doanh có thể kiểm chứng bằng dữ liệu.

Bài 11. Phân tích Pareto 80/20

Sắp xếp sản phẩm theo Revenue giảm dần, tính cumulative revenue và cumulative revenue share. Xác định bao nhiêu % sản phẩm tạo ra 80% doanh thu. Lặp lại cho khách hàng.

Câu hỏi: Quy luật 80/20 có xuất hiện trong dữ liệu này hay không? Không được kết luận trước khi tính toán.

6. Sản phẩm nộp

- 01 Jupyter Notebook (.ipynb) có code, output và nhận xét.
- 01 báo cáo trả lời câu hỏi.
- Tối thiểu 5 biểu đồ; chỉ chuyển dữ liệu đã aggregate sang Pandas để vẽ.
- Ít nhất 6 câu hỏi kinh doanh được trả lời bằng dữ liệu.
- Kết luận gồm 3–5 business insights và 3 đề xuất hành động.

7. Rubric chấm điểm

Hạng mục	Điểm
Đọc dữ liệu, schema, data understanding	1.0
Data cleaning và feature engineering	1.5
KPI bán hàng	1.5
Phân tích thời gian, sản phẩm, thị trường	2.0
Customer Analytics + RFM	1.5
Spark SQL	1.0
Business insights và recommendations	1.0
Trình bày notebook/biểu đồ/code	0.5
Tổng	10.0

8. Câu hỏi thảo luận cuối bài

40. Vì sao Revenue phải được tạo từ Quantity $\times$ UnitPrice thay vì chỉ phân tích Quantity?
41. Tại sao không nên collect() hoặc toPandas() toàn bộ hơn một triệu dòng?
42. Tại sao phải tách phân tích sales_clean và sales_customer?
43. Việc loại giao dịch hủy có thể làm mất thông tin kinh doanh nào?
44. RFM mô tả giá trị khách hàng ở khía cạnh nào và còn thiếu thông tin gì?
45. Nếu dữ liệu tăng lên hàng trăm triệu dòng, phần nào của notebook vẫn giữ nguyên về tư duy phân tích?

---o0o---

(Hết)